

Task 1.1 — Revisão de Literatura

Modelos de Segmentação para Poros em Lâminas Petrográficas

Equipe A — LCCMat-UnB

Projeto: Segmentação de Lâminas Petrográficas

23 de setembro de 2026

Repositório: <https://github.com/LCCMat-UnB/segmentacao-laminas>

Contexto

Este documento registra a Task 1.1 da Equipe A: *buscar na literatura modelos de segmentação de imagens já aplicados ou testados e transferíveis para o contexto do projeto*. O problema-alvo é segmentar poros em fotografias de lâminas delgadas impregnadas com resina epóxi azul. O método selecionado ao fim da Task 1 será reaproveitado na segmentação de grãos (Task 2).

O documento está organizado em cinco partes: famílias de modelos encontradas (Seção 1), tabela comparativa dos estudos em rochas (Seção 2), arquiteturas candidatas (Seção 3), implicações para o projeto (Seção 4) e a proposta de modelo e de fluxo de trabalho (Seções 5 e 6).

Equipe

Equipe A	Membro 1	Larissa Marques Quirino
	Membro 2	William de Souza Jota Filho

Posição na etapa (Task 1 — Prospecção de modelos, poros):

- ☒ 1.1 Buscar na literatura modelos aplicados/testados para segmentação de imagens (*este documento*);
- ☐ 1.2 Estudar o desempenho de diferentes modelos de segmentação via IA, orientados pela literatura consultada;
- ☐ 1.3 Determinar o(s) melhor(es) modelo(s) candidato(s) para aplicação em escala;
- ☐ 1.4 Documentar decisões e viabilizar a produção de um paper.

Metodologia da busca

- **Fontes:** busca web geral, arXiv, API Crossref (metadados e DOI), Semantic Scholar e OpenAlex (resumos).
- **Termos (em inglês):** *pore segmentation thin section blue epoxy deep learning; semantic segmentation sandstone/carbonate thin section; Segment Anything petrographic thin section; DINOv2/DINOv3 rock image segmentation; vision transformer grain segmentation thin section; pre-salt carbonate thin section deep learning; noisy pseudo labels segmentation.*
- **Inclusão:** (a) segmentação de poros ou grãos em lâminas; (b) segmentação de poros em outras modalidades de rocha (micro-CT, MEV) com método transferível; (c) arquiteturas e ferramentas genéricas de referência usadas nesses trabalhos.
- **Exclusão:** trabalhos sem resultado quantitativo ou comparativo, exceto arquiteturas e ferramentas de referência citadas no item (c).

Siglas usadas. PPL/XPL: luz plano-polarizada / polarizadores cruzados; MEV: microscopia eletrônica de varredura; micro-CT: microtomografia de raios X; MICP: porosimetria por injeção de mercúrio; QEMSCAN: mineralogia quantitativa automatizada por MEV; LBM/PNM/CFD: simulação de fluxo por Lattice Boltzmann, rede de poros e dinâmica dos fluidos computacional; IoU/mIoU: interseção sobre união (média entre classes); mPA: acurácia média por classe; RF: Random Forest.

Autor	William de Souza Jota Filho
--------------	-----------------------------

1 Famílias de modelos encontradas

1.1 Aprendizado de máquina clássico (atributos + classificador)

Classificadores supervisionados — Random Forest [1], *gradient boosting* [2], SVM — aplicados pixel a pixel (ou por superpixel [3]) sobre atributos calculados à mão: cor, filtros multiescala e textura. É o paradigma das ferramentas interativas ilastik [4] e Trainable Weka Segmentation [5], em que o especialista anota poucos rabiscos e o classificador é treinado em segundos.

- [Rubo et al. \[6\]](#): filtros convolucionais fixos + RNA/Random Forest em lâminas sob luz visível para mineralogia e porosidade; RMSE 8,99% e R^2 0,82 contra microanálise. Indica que atributos de cor e textura bem escolhidos já produzem estimativas úteis de porosidade.
- [Brondolo and Beaussant \[7\]](#): Random Forest aparece entre os *baselines* (com Otsu, K-means e U-Net) em micro-CT de rocha e é superado pelo DINOv2 — é referência de comparação usual no domínio, não o método vencedor.
- [Risha \[8\]](#): limiar de cor e K-means (não supervisionados) em arenitos *tight*; correlação fraca a moderada com MICP (r 0,32–0,62), o que ilustra o limite de métodos sem rótulos.
- [jPOR \[9\]](#): macro de ImageJ para porosidade óptica total em lâminas com resina azul por limiar de cor — mesmo princípio do *rockface*.

1.2 CNNs encoder-decoder (padrão do domínio)

U-Net [10], UNet++ [11], Attention U-Net [12], DeepLabv3+ [13] e nnU-Net [14].

- [Saxena et al. \[15\]](#): compara VGG, ResNet, U-Net e DeepLabv3+ em arenitos. No problema binário poro $\times$ mineral, a maioria dos modelos foi satisfatória; em 10 classes, DeepLabv3+ com ResNet-18 foi mais contínuo. O desempenho por classe acompanha a quantidade de rótulos.
- [Zhong et al. \[16\]](#): DeepLabv3+ com atenção, duas polarizações empilhadas em 6 canais; mPA 89,8% e mIoU 81,2%.
- [de Mello et al. \[17\]](#): U-Net em carbonatos com PPL+XPL e rótulos derivados de QEMSCAN; $R^2 > 0,97$ na distribuição mineral em fácies vistas e 0,88 em não vistas.
- [Hayatdavoudi et al. \[18\]](#): micro-CT de arenito (5.000 fatias); FCN, encoder-decoder, multiescala, dilatadas e atenção contra Otsu. Avalia além do pixel: simulação de fluxo (LBM, PNM, CFD) para permeabilidade e fator de formação. As CNNs superam o limiar automático de Otsu nas duas frentes; os melhores modelos foram EfficientNetB0-UNet, VGG16-UNet e ENet.

1.3 Transformers

SegFormer [19], Swin-Unet [20] e Mask2Former [21].

- [Zheng et al. \[22\]](#) (Trans-SedNet): ViT *dual-modal* (PPL+XPL) para 10 tipos de grão; **a versão dual-modal supera a de modalidade única.**
- [Ren et al. \[23\]](#) (MCAT): transformer com atenção multicanal que integra imagens sob diferentes ângulos de iluminação; *copy-paste* como aumento de dados para amostra pequena.

1.4 Modelos de fundação

Família SAM

SAM [24], SAM 2 [25], SAM 3 [26] e μ SAM para microscopia [27].

- Ren et al. [28] (Petro-SAM): encoder do SAM (ViT-B/L/H) treinável, 7 vistas polarizadas (1 PPL + 6 XPL), 1.400 grupos de imagens. Bordas de grão: mIoU 48,2% contra 22,0% do ECPN [29]; litologia: mIoU 86,3% contra 85,0% da FCN. Rotulagem com pré-rótulos do SAM refinados por especialistas.
- Wang et al. [30] (Auto-SAM): SAM com fusão PPL/XPL após o encoder, prompts automáticos (Grad-CAM + GLCM) e perda BCE + Dice; supera ViT e CNN em mIoU/mPA, e a entrada dual-modal supera a modalidade única.
- Ma et al. [31] (RockSAM): o SAM original tem desempenho ruim em CT/MEV de rocha; o ajuste fino (*fine-tuning*) melhora muito o resultado.
- Zhang et al. [32] (SAMamba3D): encoder SAM quase congelado + Mamba para micro-CT 3D multifásico; iguala ou supera baselines 3D com menos retreino.

Família DINO

DINOv2 [33] e DINOv3 [34].

- Brondolo and Beaussant [7]: DINOv2 em micro-CT de rocha, congelado e com LoRA [35], contra Otsu, K-means, Random Forest, U-Net e ResNet152. **DINOv2 com LoRA se destaca fora da distribuição, com dados escassos e ruidosos; as máscaras previstas às vezes parecem melhores que os próprios alvos.**
- DINOv3 [34]: o *Gram anchoring* evita a degradação das representações densas em treinos longos; estado da arte em segmentação com *backbone* congelado.
- Xu et al. [36]: features DINOv3 em segmentação *few-shot* em 6 datasets médicos — evidência de transferência de imagens naturais para domínios distantes.

1.5 Detecção, instâncias e trabalhos de contexto

- Qaiser et al. [37] (PoreViT): tipo de poro (classes de Lucia) em carbonatos, a partir de poros já segmentados; macro-F1 0,92 com 4.115 poros de 25 lâminas. Útil para o fluxo de classificação de poros previsto para etapas posteriores.
- **Pré-sal brasileiro:** Basso et al. [38] usa 800 lâminas da Fm. Barra Velha (6 poços, 3 campos da Bacia de Santos), escaneadas em PPL e XPL a 6.400 dpi, tingidas com alizarina e impregnadas com resina azul. A tarefa é classificação de fácies (5, 9 e 23 classes): recorte automático da lâmina com YOLOv8, duas CNNs leves pré-treinadas em paralelo (uma para PPL, outra para XPL; 2,5–11,7 M parâmetros), MLP de classificação e hiperparâmetros via Optuna. F1 na validação: 0,795 / 0,768 / 0,528; no teste cego com um poço fora do treino, caiu para 0,615 / 0,507 / $\leq 0,29$.
- Li et al. [39] (DeepCarbonate): dataset público de carbonatos (PPL/XPL/luz refletida, 22 classes).

2 Tabela comparativa: estudos no domínio de rochas

Apenas estudos com resultado quantitativo ou comparativo relatado. Os números não são diretamente comparáveis entre linhas: materiais, modalidades de imagem, classes e métricas diferem.

Tabela 1: Estudos de segmentação em rochas com resultado relatado.

Ref.	Material / imagem	Alvo	Modelo(s)	Resultado relatado
[6]	Lâminas, luz visível	Mineralogia + porosidade	Filtros conv. + RNA/RF	RMSE 8,99%; R^2 0,82 vs microanálise
[15]	Arenito, RGB	Poros/mineral; 10 classes	VGG, ResNet18, U-Net, DeepLabv3+	2 classes: maioria satisfatória; 10 classes: DeepLabv3+ melhor
[16]	Arenito, PPL+XPL (6 canais)	Minerais + poros	DeepLabv3+ com atenção	mPA 89,8%; mIoU 81,2%
[18]	Micro-CT de arenito	Poros/matriz	CNNs vs Otsu	CNN > Otsu em IoU e em permeabilidade
[17]	Carbonato, PPL+XPL, QEMSCAN	6 classes (inclui poros)	U-Net	$R^2 > 0,97$ (fácies vistas); 0,88 (não vistas)
[8]	26 arenitos <i>tight</i>	Poros e gargantas	Limiar de cor, K-means	r com MICP: 0,32–0,62
[22]	Sedimentar, PPL+XPL	10 tipos de grão	ViT dual-modal	Dual-modal > modalidade única
[28]	1 PPL + 6 XPL	Bordas + litologia	Encoder SAM	mIoU bordas 48,2% (vs 22,0%); litologia 86,3% (vs 85,0%)
[30]	PPL+XPL	Grãos	SAM + fusão	> ViT/CNN em mIoU e mPA
[7]	Micro-CT de rocha	Segmentação	DINOv2 + LoRA (vs Otsu, K-means, RF, U-Net)	IoU 0,80 vs 0,78 (U-Net); 0,74 com 4 imagens de treino
[31]	CT/MEV de rocha	Segmentação	SAM com fine-tuning	Fine-tuning $\gg$ SAM original
[37]	25 lâminas de carbonato	Tipo de poro	ViT + CNN	macro-F1 0,92
[38]	Pré-sal, PPL+XPL, resina azul	Fácies (5/9/23 classes)	2 CNNs leves + MLP	F1 0,795 / 0,768 / 0,528; poço cego: 0,615 / 0,507 / $\leq 0,29$

3 Arquiteturas candidatas

Tabela 2: Arquiteturas candidatas avaliadas para poros e para a Task 2 (grãos).

Candidato	Treino	Pontos fortes (poros)	Uso na Task 2 (grãos)	Riscos	Implementação
Limiar HSV / Otsu (rockface, jPOR)	Nenhum	Referência; rápido	Fraco (grãos não se separam por cor)	Não é aprendido; sensível a tingimento	rockface, OpenCV
Random Forest pixel a pixel (banco de filtros multiescala)	Rabiscos de especialistas (CPU; segundos)	Supervisionado por anotação; interpretável (importância de atributos); poucos rótulos [4, 6]	Forte: mesmos atributos + atributos XPL multiângulo; classe “borda” + <i>watershed</i>	Contexto espacial limitado ao maior σ ; generalização entre lotes	scikit-learn, scikit-image, ilastik

Candidato	Treino	Pontos fortes (poros)	Uso na Task 2 (grãos)	Riscos	Implementação
Gradient boosting (XGBoost / LightGBM)	Idem RF	Mesmos atributos; costuma ganhar alguns pontos sobre RF	Idem RF	Mais hiperparâmetros; sobreajuste com poucos rótulos	xgboost, lightgbm
U-Net (encoder ResNet34 / EfficientNet)	Máscaras densas; GPU	Padrão do domínio; bordas finas	Aceita N canais (PPL+XPL); instâncias exigem pós-processamento	Exige rótulos densos; pode imitar o limiar	segmentation_models_pytorch
DeepLabv3+	Idem U-Net	Contexto multiescala; boa continuidade [15]	Já usado com PPL+XPL [16]	Bordas menos nítidas que a U-Net	segmentation_models_pytorch
nnU-Net 2D	Idem U-Net	Baseline forte e reprodutível	Idem U-Net	Treino pesado	nnunetv2
SegFormer (B2)	Idem U-Net	Contexto global	Bom com dual-modal [22]	Precisa de mais dados que CNN	HF transformers
DINOv3 / SAM 2	Pré-treino massivo + ajuste	Robustez a rótulos ruidosos [7]; bordas precisas	Instâncias de grão [28, 30]	Complexidade; GPU; licença; SAM original ruim em rocha [31]	dinov3, sam2

4 Implicações para o nosso caso

1. **O problema binário com resina azul é “fácil” no pixel médio [15].** Isso torna métodos clássicos com atributos bem escolhidos competitivos em princípio. A dificuldade real está em bordas, microporosidade e artefatos — justamente onde se espera que redes profundas mostrem vantagem, se houver. A comparação precisa focar nesses casos, com um conjunto de teste pequeno **corrigido manualmente** por especialistas.
2. **Rótulos do rockface = pseudo-rótulos.** O IoU contra o rockface mede *concordância com o rockface*, não acerto. Treinar com **anotação direta de especialistas** evita herdar os erros do limiar; as máscaras do rockface ficam como baseline.
3. **Métricas petrofísicas, não só por pixel.** A literatura valida contra porosidade, permeabilidade e fator de formação [18], contra MICP [8] e contra microanálise [6]. Alinhar com a task de métricas petrofísicas do rockface (README, @oi-silva).
4. **Generalização entre lâminas e poços.** No pré-sal, o F1 caiu de 0,768 para 0,507 (9 classes) quando o teste passou a ser um poço fora do treino [38]. A divisão treino/teste deve ser feita **por lâmina (idealmente por poço)**, nunca por recortes da mesma lâmina, e as anotações devem cobrir lâminas com preparo, tingimento e iluminação diferentes.
5. **Coerência com a Task 2.** Os trabalhos de grãos usam PPL+XPL. Num classificador pixel a pixel, a entrada multimodal é natural: basta concatenar os atributos de cada polarização (e de cada ângulo XPL) no vetor do pixel, sem adaptar arquitetura.
6. **Risco de atalho por cor [40]:** o modelo pode aprender a tonalidade específica de um lote de resina ou de iluminação em vez da estrutura do poro. Com atributos de cor explícitos o risco é ainda maior; testar com normalização de cor e com lâminas de lotes diferentes, e inspecionar a importância dos atributos.
7. **Lacunas encontradas (oportunidade de paper):** não foi encontrado benchmark público de **segmentação de poros com resina azul** com máscaras por pixel; faltam comparações diretas entre **classificadores clássicos com anotação esparsa e limiares de cor** medidas

em métricas petrofísicas; e poucos trabalhos avaliam o **efeito de treinar com rótulos gerados por limiar**.

5 Proposta de *shortlist* para a Task 1.2

Prioridade	Candidato	Justificativa
0	Limiar HSV/Otsu (rockface)	Baseline obrigatório.
1	Random Forest pixel a pixel + banco de filtros	Candidato principal (Seção 6): supervisionado por anotação, interpretável, roda em CPU.
1	LightGBM/XGBoost (mesmos atributos)	Alternativa clássica direta; mesmo pipeline, troca só o classificador.
2	RF por superpixel (SLIC)	Menos pixels a classificar; atributos de região (forma, textura).
2	U-Net (segmentation_models_pytorch)	Referência de <i>deep learning</i> ; obrigatória para medir o ganho ou a perda do método clássico.
—	DINOv3, SAM 2	Fora do escopo desta etapa; registrados para trabalho futuro.

Saída esperada da Task 1.2: comparação dos candidatos acima contra o baseline, com métricas por pixel (em teste corrigido por especialistas) e métricas petrofísicas → subsidia a escolha do modelo na Task 1.3, que será reutilizado na Task 2.

6 Conclusão: modelo escolhido

A escolha abaixo é a hipótese de trabalho que sai da revisão; ela será confirmada ou revista com os resultados da Task 1.2 e formalizada na Task 1.3.

Autor	William de Souza Jota Filho
Modelo escolhido	Random Forest pixel a pixel sobre banco de filtros multiescala , treinado com anotações esparsas (rabiscos) de especialistas
Paradigma	ML clássico supervisionado: atributos definidos à mão + classificador de conjunto de árvores
Comparar contra	Limiar de cor (rockface / jPOR [9]); LightGBM com os mesmos atributos; U-Net (ResNet34) como referência de <i>deep learning</i> .
Critério de troca	(i) Se o LightGBM superar o RF no teste corrigido e nas métricas petrofísicas com margem relevante (ex.: ≥ 2 pontos de IoU ou erro de porosidade menor), ele passa a ser o classificador; o banco de atributos e o fluxo são mantidos. (ii) Se a U-Net superar ambos com margem relevante nas lâminas/poços de teste, em especial em bordas e microporosidade, a escolha é reavaliada na Task 1.3, pesando o ganho contra o custo de rótulos densos e GPU.

6.1 Por que Random Forest com banco de filtros

1. **Supervisionado por anotação, com pouca anotação.** O especialista marca com rabiscos algumas regiões de poro e de sólido; só esses pixels entram no treino. Com milhares de pixels rotulados por classe o RF já converge, e o treino leva segundos. Esse ciclo “anotar $\rightarrow$ treinar $\rightarrow$ ver o erro $\rightarrow$ anotar onde errou” é o fluxo consolidado do ilastik [4] e do Trainable Weka Segmentation [5].
2. **Evidência no domínio.** Em lâminas petrográficas, filtros fixos + RNA/RF estimaram porosidade e mineralogia com R^2 0,82 contra microanálise [6]. A evidência direta a favor do RF é limitada: em micro-CT ele aparece como *baseline* e é superado pelo DINOv2 [7], e as CNNs superam limiares simples [18]. O argumento é outro: como o problema poro $\times$ sólido com resina azul é em grande parte separável por cor [15], a capacidade extra de uma CNN serve sobretudo aos casos de borda, que atributos multiescala também endereçam. Essa hipótese é exatamente o que a comparação com a U-Net na Task 1.2 vai testar.
3. **Interpretável e auditável.** A importância de atributos (Gini ou permutação) mostra se o modelo decide por cor da resina, por borda ou por textura. Isso facilita a validação com petrógrafos e a detecção de atalhos de cor [40].
4. **Robusto e barato.** O RF tem poucos hiperparâmetros sensíveis, não exige GPU, tolera atributos redundantes e dá probabilidades por pixel, úteis para achar as regiões incertas a anotar.
5. **Um único método para poros e grãos.** Na Task 2, o mesmo banco de filtros é aplicado a PPL e a cada ângulo de XPL, somam-se atributos de extinção entre ângulos e o mesmo tipo de classificador é retreinado com as classes grão / borda / poro / matriz. Isso atende ao critério de consistência metodológica da etapa.
6. **Ferramental pronto.** `scikit-learn` (`RandomForestClassifier`), `scikit-image` (`feature.multiscale_basic_features`, filtros, `watershed`) e ilastik (interface de anotação e execução em lote sem interface) permitem validar a ideia em poucos dias.

Riscos e mitigação.

- *Contexto espacial limitado*: o pixel só “vê” até a escala do maior filtro ($\approx 3\sigma_{\max}$) $\rightarrow$ testar σ maiores (até 16 px) e, se necessário, uma segunda passada (*auto-context*: probabilidades da 1ª passada filtradas viram atributos da 2ª).
- *Generalização entre lâminas*: variação de tingimento e iluminação $\rightarrow$ normalização de cor por lâmina, anotação distribuída em várias lâminas/poços e validação cruzada agrupada por lâmina.
- *Custo em escala*: ~ 150 atributos por pixel em imagens gigapixel $\rightarrow$ processamento em blocos com sobreposição (*dask*), *float32* e seleção dos atributos mais importantes.
- *Grãos em contato (Task 2)*: classificação pixel a pixel não separa instâncias $\rightarrow$ classe explícita de borda, atributos XPL multiângulo e *watershed* marcado.

6.2 Como o modelo funciona

1. Atributos por pixel. Cada pixel é descrito por um vetor $\mathbf{x} \in \mathbb{R}^d$ obtido aplicando filtros clássicos a canais de cor, em várias escalas σ (Tabela 3). Um filtro em escala σ “olha” uma vizinhança de raio $\approx 3\sigma$, então o conjunto de escalas dá ao classificador contexto local de poucos pixels até dezenas de pixels.

Grupo	Atributos	O que captura
Cor	RGB, HSV, CIE L*a*b* (valor do pixel)	Resina azul (matiz H, canal b*)
Intensidade	Suavização gaussiana G_σ	Cor média da vizinhança; reduz ruído
Borda	Magnitude do gradiente de gaussiana; diferença de gaussianas (DoG)	Contornos poro/grão
Forma	Laplaciano de gaussiana (LoG); autovalores da Hessiana	Poros pequenos (blobs), gargantas alongadas
Textura	Autovalores do tensor de estrutura	Microporosidade, cimento vs grão
Escalas: $\sigma \in \{0,7; 1; 1,6; 3,5; 5; 10\}$ px Canais filtrados: L*, b*, S Total: $9 + 3 \times 6 \times 8 = 153$ atributos		

Tabela 3: Banco de atributos por pixel para a Task 1 (escalas e filtros no padrão do ilastik). Os 9 atributos de cor são os valores brutos em RGB, HSV e L*a*b*; os 8 filtros por escala e canal são: gaussiana, gradiente, DoG, LoG, 2 autovalores da Hessiana e 2 do tensor de estrutura.

2. Random Forest. O RF [1] treina T árvores de decisão, cada uma sobre uma amostra *bootstrap* dos pixels anotados; em cada nó, a árvore escolhe o melhor corte (menor impureza de Gini) entre um subconjunto aleatório de $\sqrt{d}$ atributos. A aleatoriedade descorrelaciona as árvores, e a média reduz a variância. A probabilidade de poro é a média das árvores:

$$\hat{p}(\text{poro} \mid \mathbf{x}) = \frac{1}{T} \sum_{t=1}^T p_t(\text{poro} \mid \mathbf{x}). \quad (1)$$

3. Pós-processamento. A máscara é $\hat{p} \geq \tau$, com τ ajustado na validação (partida: 0,5), seguida de abertura morfológica e remoção de objetos menores que uma área mínima $A_{\min}$ definida com os especialistas (ruído $\times$ microporo).

Parâmetros iniciais.

Parâmetro	Valor inicial (ajustar na Task 1.2)
<code>n_estimators</code>	200 (estável acima de ~ 100)
<code>max_features</code>	"sqrt"
<code>max_depth / min_samples_leaf</code>	None / 5
<code>class_weight</code>	"balanced_subsample" (poros são minoria)
Amostragem de treino	até 50 mil pixels anotados por classe por lâmina
Validação	GroupKFold com grupo = lâmina (ou poço)
Busca de hiperparâmetros	<code>max_depth</code> , <code>min_samples_leaf</code> , conjunto de σ

6.3 Fluxo proposto: segmentação de poros (Task 1)




Figura 1: Fluxo proposto para a Task 1. Blocos azuis: processamento; tracejados vinho: anotação, treino e avaliação.

- Fase 0 (validação rápida):** no ilastik, anotar 3–5 lâminas com rabiscos e inspecionar a probabilidade de poro. Se as bordas e os poros pequenos já saem corretos, a abordagem é viável.
- Fase 1:** reproduzir o pipeline em Python (`scikit-image` + `scikit-learn`), com as anotações exportadas, validação cruzada por lâmina e ajuste de τ e $A_{\min}$.
- Fase 2:** anotação ativa nas regiões incertas; seleção de atributos; teste do LightGBM e, se preciso, *auto-context*.
- Avaliação:** sempre no conjunto corrigido por especialistas e separado por lâmina/poço, com métricas por pixel e petrofísicas.

6.4 Fluxo proposto: segmentação de grãos (Task 2)

O XPL é essencial para grãos: grãos vizinhos têm respostas ópticas diferentes sob polarização cruzada (por exemplo, extinção em ângulos distintos), o que ajuda a separar grãos em contato, e as abordagens dual-modal superam as de modalidade única [22, 30]. No RF isso entra como atributos:




Figura 2: Fluxo proposto para a Task 2, reaproveitando o banco de atributos e o classificador da Task 1.

para cada pixel, a intensidade máxima, mínima, a amplitude e o desvio padrão ao longo dos ângulos de XPL resumem o comportamento de extinção. A classe explícita de borda e o *watershed* marcado transformam a classificação pixel a pixel em grãos individuais.

6.5 Anotações

Poros (Task 1)

- **Treino:** rabiscos esparsos de especialistas no ilastik (ou napari), classes poro e sólido, distribuídos em várias lâminas e poços. Rabiscos devem cobrir de propósito bordas, poros pequenos, bolhas e variações de tingimento, não só o “miolo” fácil.
- **Teste de referência:** subconjunto de janelas com máscara **densa** corrigida por especialistas, estratificado por lâmina/poço e enriquecido com casos difíceis (bordas de poro, microporosidade, bolhas, arrancamentos, variação de tingimento). Nenhuma lâmina de teste recebe rabiscos de treino.
- **Anotação ativa:** priorizar novos rabiscos onde o RF está incerto ($\hat{p}$ próximo de 0,5) ou discorda do rockface.
- **Uso do rockface:** apenas como baseline de comparação; se usado para acelerar a anotação (pré-rótulo), toda região deve ser revisada, para não reintroduzir o viés do limiar.
- **Regras de rotulagem a definir:** microporosidade (azul difuso) como poro, sólido ou terceira classe; pixels de borda ambíguos ficam sem rabisco (não entram no treino).
- **Concordância entre anotadores:** dois especialistas anotam o mesmo subconjunto de teste para medir a variabilidade humana, que é o teto realista das métricas.

Grãos (Task 2)

- **Não há rótulos prontos.** Anotar com rabiscos as classes grão, borda, poro e matriz sobre a pilha PPL + XPL; a borda é marcada com linhas finas (1–3 px) nos contatos entre grãos.
- **Teste:** poucas janelas com grãos delineados um a um (máscara de instâncias, um identificador por grão), da qual se derivam o mapa de bordas e a máscara semântica; os poros vêm da Task 1.
- **Iteração:** treinar, inspecionar grãos fundidos ou fragmentados após o *watershed* e adicionar rabiscos de borda nesses locais.
- **Validação qualitativa:** especialistas avaliam amostras de máscaras e parâmetros granulométricos derivados, conforme exigido na etapa.

Referências

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001. doi:[10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [2] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016. doi:[10.1145/2939672.2939785](https://doi.org/10.1145/2939672.2939785).
- [3] Radhakrishna Achanta, Appu Shaji, Kevin Smith, Aurelien Lucchi, Pascal Fua, and Sabine Süsstrunk. SLIC superpixels compared to state-of-the-art superpixel methods. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 34(11):2274–2282, 2012. doi:[10.1109/TPAMI.2012.120](https://doi.org/10.1109/TPAMI.2012.120).
- [4] Stuart Berg, Dominik Kutra, Thorben Kroeger, Christoph N. Straehle, Bernhard X. Kausler, Carsten Haubold, Martin Schiegg, Janez Ales, Thorsten Beier, Markus Rudy, et al. ilastik: interactive machine learning for (bio)image analysis. *Nature Methods*, 16:1226–1232, 2019. doi:[10.1038/s41592-019-0582-9](https://doi.org/10.1038/s41592-019-0582-9).
- [5] Ignacio Arganda-Carreras, Verena Kaynig, Curtis Rueden, Kevin W. Eliceiri, Johannes Schindelin, Albert Cardona, and H. Sebastian Seung. Trainable Weka segmentation: a machine learning tool for microscopy pixel classification. *Bioinformatics*, 33(15):2424–2426, 2017. doi:[10.1093/bioinformatics/btx180](https://doi.org/10.1093/bioinformatics/btx180).
- [6] Rafael Andreello Rubo, Cleyton de Carvalho Carneiro, Mateus Fontana Michelon, and Rafael dos Santos Gioria. Digital petrography: Mineralogy and porosity identification using machine learning algorithms in petrographic thin section images. *Journal of Petroleum Science and Engineering*, 183:106382, 2019. doi:[10.1016/j.petrol.2019.106382](https://doi.org/10.1016/j.petrol.2019.106382).
- [7] Florent Brondolo and Samuel Beaussant. DINOv2 rocks geological image analysis: Classification, segmentation, and interpretability. *Journal of Rock Mechanics and Geotechnical Engineering*, 17:6853–6867, 2025. doi:[10.1016/j.jrmge.2025.01.057](https://doi.org/10.1016/j.jrmge.2025.01.057). arXiv:2407.18100.
- [8] Muhammad Risha. AI-assisted thin section image processing for pore-throat characterization in tight clastic rocks, 2025.
- [9] Carl Grove and Dougal A. Jerram. jPOR: An ImageJ macro to quantify total optical porosity from blue-stained thin sections. *Computers & Geosciences*, 37(11):1850–1859, 2011. doi:[10.1016/j.cageo.2011.03.002](https://doi.org/10.1016/j.cageo.2011.03.002).
- [10] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-Net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, volume 9351 of *LNCS*, pages 234–241, 2015. doi:[10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28).

- [11] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. UNet++: A nested U-Net architecture for medical image segmentation. In *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA)*, volume 11045 of *LNCS*, pages 3–11, 2018. doi:[10.1007/978-3-030-00889-5_1](https://doi.org/10.1007/978-3-030-00889-5_1).
- [12] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y. Hammerla, Bernhard Kainz, Ben Glocker, and Daniel Rueckert. Attention U-Net: Learning where to look for the pancreas, 2018. arXiv:1804.03999.
- [13] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff, and Hartwig Adam. Encoder-decoder with atrous separable convolution for semantic image segmentation. In *European Conference on Computer Vision (ECCV)*, volume 11211 of *LNCS*, pages 833–851, 2018. doi:[10.1007/978-3-030-01234-2_49](https://doi.org/10.1007/978-3-030-01234-2_49).
- [14] Fabian Isensee, Paul F. Jaeger, Simon A. A. Kohl, Jens Petersen, and Klaus H. Maier-Hein. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18:203–211, 2021. doi:[10.1038/s41592-020-01008-z](https://doi.org/10.1038/s41592-020-01008-z).
- [15] Nishank Saxena, Ruarri J. Day-Stirrat, Amie Hows, and Ronny Hofmann. Application of deep learning for semantic segmentation of sandstone thin sections. *Computers & Geosciences*, 152: 104778, 2021. doi:[10.1016/j.cageo.2021.104778](https://doi.org/10.1016/j.cageo.2021.104778).
- [16] Jinzhi Zhong, Yanjun Meng, and Zehao Liu. Multichannel sandstone thin sections identification based on improved DeepLab V3 Plus neural network. *ACS Omega*, 9:28611–28625, 2024. doi:[10.1021/acsomega.4c02692](https://doi.org/10.1021/acsomega.4c02692).
- [17] Jean Pablo Vieira de Mello, Matheus Augusto Alves Cuglieri, Leandro P. de Figueiredo, Fernando Bordignon, Marcelo Ramalho Albuquerque, Rodrigo Surmas, and Bruno Cavalcanti de Paula. Deep mineralogical segmentation of thin section images based on QEMSCAN maps, 2025. arXiv:2505.17008.
- [18] Mazaher Hayatdavoudi, Mohammad Emami Niri, and Ahmad Kalhor. Comparative analysis of sandstone microtomographic image segmentation using advanced convolutional neural networks with pixelwise and physical accuracy evaluation. *Scientific Reports*, 15:22164, 2025. doi:[10.1038/s41598-025-07211-2](https://doi.org/10.1038/s41598-025-07211-2).
- [19] Enze Xie, Wenhai Wang, Zhiding Yu, Anima Anandkumar, Jose M. Alvarez, and Ping Luo. SegFormer: Simple and efficient design for semantic segmentation with transformers. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. arXiv:2105.15203.
- [20] Hu Cao, Yueyue Wang, Joy Chen, Dongsheng Jiang, Xiaopeng Zhang, Qi Tian, and Manning Wang. Swin-Unet: Unet-like pure transformer for medical image segmentation. In *European Conference on Computer Vision Workshops (ECCVW)*, 2022. arXiv:2105.05537.
- [21] Bowen Cheng, Ishan Misra, Alexander G. Schwing, Alexander Kirillov, and Rohit Girdhar. Masked-attention mask transformer for universal image segmentation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1290–1299, 2022.
- [22] Dongyu Zheng, Li Hou, Xiumian Hu, Mingcai Hou, Kai Dong, Sihai Hu, Runlin Teng, and Chao Ma. Sediment grain segmentation in thin-section images using dual-modal vision transformer. *Computers & Geosciences*, 191:105664, 2024. doi:[10.1016/j.cageo.2024.105664](https://doi.org/10.1016/j.cageo.2024.105664).
- [23] Yili Ren, Xin Li, Jianzhong Bi, Yunying Zhang, Qianxiao Su, Wenjie Wang, and Hongjue Li. Multi-channel attention transformer for rock thin-section image segmentation. *Journal of Engineering Research*, 13:730–740, 2025. doi:[10.1016/j.jer.2024.04.009](https://doi.org/10.1016/j.jer.2024.04.009).

- [24] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C. Berg, Wan-Yen Lo, Piotr Dollár, and Ross Girshick. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4015–4026, 2023.
- [25] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, et al. SAM 2: Segment anything in images and videos, 2024. arXiv:2408.00714.
- [26] Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, et al. SAM 3: Segment anything with concepts, 2025. arXiv:2511.16719.
- [27] Anwai Archit, Luca Freckmann, Sushmita Nair, Nabeel Khalid, Paul Hilt, Vikas Rajashekar, Marei Freitag, Carolin Teuber, Melanie Spitzner, Constanza Tapia Contreras, Genevieve Buckley, Sebastian von Haaren, Sagnik Gupta, Marian Grade, Matthias Wirth, Günter Schneider, Andreas Dengel, Sheraz Ahmed, and Constantin Pape. Segment anything for microscopy. *Nature Methods*, 22(3):579–591, 2025. doi:[10.1038/s41592-024-02580-4](https://doi.org/10.1038/s41592-024-02580-4).
- [28] Yili Ren, Shiqi Wen, Li Hou, Dingwen Xiao, Weiming Zhang, Caleb Chen Cao, Lin Wang, Zilu Zheng, Qianxiao Su, Mingjun Zhao, and Lei Chen. From boundaries to semantics: Prompt-guided multi-task learning for petrographic thin-section segmentation, 2026. arXiv:2604.14805.
- [29] Ping Zhang, Jiazhou Zhou, Wen Zhao, Xuyang Li, and Liu Pu. The edge segmentation of grains in thin-section petrographic images utilising extinction consistency perception network. *Complex & Intelligent Systems*, 10:1231–1245, 2023. doi:[10.1007/s40747-023-01208-y](https://doi.org/10.1007/s40747-023-01208-y).
- [30] Yijun Wang, Dongyu Zheng, Mingcai Hou, Hongjun Li, Wei Zeng, Caihua Chen, Sixuan Wu, Yujie Gao, and Yifan Bai. An auto-prompting segment anything model for dual-modal grain segmentation in rock images. *Applied Computing and Geosciences*, 31:100375, 2026. doi:[10.1016/j.acags.2026.100375](https://doi.org/10.1016/j.acags.2026.100375).
- [31] Zhaoyang Ma, Xupeng He, Shuyu Sun, Bicheng Yan, Hyung Kwak, and Jun Gao. Zero-shot digital rock image segmentation with a fine-tuned segment anything model, 2023. arXiv:2311.10865.
- [32] R. Zhang, X. Song, L. Zhu, B. Bijeljic, G. Li, and M. J. Blunt. SAMamba3D: adapting segment anything for generalizable 3D segmentation of multiphase pore-scale images, 2026. arXiv:2605.00916.
- [33] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2024. arXiv:2304.07193.
- [34] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, et al. DINOv3, 2025. arXiv:2508.10104.
- [35] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations (ICLR)*, 2022. arXiv:2106.09685.
- [36] G. Xu, J. K. Udupa, W. Lu, and Y. Zhang. Exploiting DINOv3-based self-supervised features for robust few-shot medical image segmentation, 2026. arXiv:2601.08078.
- [37] Yemna Qaiser, Mohammed Ishaq, Mohammed Yaqoob, Mohammed Yusuf Ansari, Isaac Sujay, Talha Khan, Harris Rabbani, Juan Carlos Laya, P. J. Moore, and Thomas Daniel Seers. Po-reViT: Automated pore typing in carbonate rocks using vision transformers and neighborhood features. *Computers & Geosciences*, 207:106071, 2026. doi:[10.1016/j.cageo.2025.106071](https://doi.org/10.1016/j.cageo.2025.106071).

- [38] Mateus Basso, João Paulo da Ponte Souza, Guilherme Furlan Chinelatto, Luis Augusto Antioniossi Mansini, and Alexandre Campana Vidal. Petrographic image classification of complex carbonate rocks from the Brazilian pre-salt using convolutional neural networks. *Scientific Reports*, 15:30700, 2025. doi:[10.1038/s41598-025-10006-0](https://doi.org/10.1038/s41598-025-10006-0).
- [39] Keran Li, Jinmin Song, Zhaoyi Zhang, Shan Ren, Yang Lan, Di Yang, Zhiwu Li, Shugen Liu, Chunqiao Yan, Xin Jin, Shaohai Yang, and Jiaxin Guo. A dataset and benchmark of carbonate thin-section images for deep learning. *Scientific Data*, 13:340, 2026. doi:[10.1038/s41597-026-06633-5](https://doi.org/10.1038/s41597-026-06633-5).
- [40] Joaquin Morales, Camila Saldivia, Rodolfo Lobo, Max del Pino, Marcos Muñoz, Giorgio Canniggia, Joaquín Catalán, Rafael Hayde, and Víctor Poblete. Visual analysis of deep learning semantic segmentation applied to petrographic thin sections. *Scientific Reports*, 15:14612, 2025. doi:[10.1038/s41598-025-99767-2](https://doi.org/10.1038/s41598-025-99767-2).